

Universidad Autónoma Metropolitana

Unidad Azcapotzalco

División de Ciencias Básicas e Ingeniería

Selección de Bandas Hiperespectrales Mediante Metaheurísticas para la Detección de Aspergillus flavus en Higos con Aprendizaje Automático

Idónea Comunicación de Resultados

que presenta:

Israel Calderón Aguilar

para obtener el grado de:

Maestro en Ciencias de la Computación

Personas directoras

Juan Villegas Cortez

Ciudad de México Marzo 2026

Resumen

La contaminación de higos por *Aspergillus flavus* representa un problema crítico para la seguridad alimentaria y la economía agrícola debido a la producción de aflatoxinas cancerígenas. Este trabajo propone un enfoque híbrido y no invasivo para optimizar su detección mediante el uso de imágenes hiperespectrales. Para resolver el desafío computacional provocado por la alta dimensionalidad inherente a estas imágenes, se implementaron dos algoritmos metaheurísticos: Algoritmos Genéticos y Optimización por Enjambre de Partículas. Estas técnicas permitieron identificar subconjuntos óptimos de bandas espectrales clave. La aptitud de cada subconjunto se evaluó utilizando la métrica F1-Score de un modelo de clasificación basado en Máquinas de Vectores de Soporte. Los resultados demostraron que es posible disminuir drásticamente la dimensionalidad de los datos y el costo computacional sin sacrificar la precisión diagnóstica, sentando así las bases para la implementación de futuros sistemas de inspección agrícola en tiempo real.

Palabras clave: Imágenes Hiperespectrales, Metaheurísticas, *Aspergillus flavus*.

Abstract

The contamination of figs by *Aspergillus flavus* represents a critical problem for food safety and the agricultural economy due to the production of carcinogenic aflatoxins. This work proposes a hybrid, non-invasive approach to optimize detection using hyperspectral imaging. To solve the computational challenge caused by the high dimensionality inherent in these images, two metaheuristic algorithms were implemented: Genetic Algorithms and Particle Swarm Optimization. These techniques allowed the identification of optimal subsets of key spectral bands. The fitness of each subset was evaluated using the F1-Score metric of a Support Vector Machine classification model. The results demonstrated that it is possible to drastically reduce data dimensionality and computational cost without sacrificing diagnostic accuracy, thereby laying the groundwork for the implementation of future real-time agricultural inspection systems.

Keywords: Hyperspectral Imaging, Metaheuristics, *Aspergillus flavus*.

Dedicatoria

// Esta sección se presenta en la versión final de su ICR. Son frases cuyo objetivo es otorgar una mención especial a las personas que te han motivado durante tu ICR.

Agradecimientos

Esta investigación ha sido financiada por el Ministerio de Ciencia e Innovación de España bajo el proyecto PID2023-147409NB-C22 financiado por MCIN-/AEI-/10.130-39/501100011033, por la Junta de Extremadura, proyecto GR24142 y por "FEDER Una manera de hacer Europa".

Índice general

Índice de figuras x

Índice de tablas xi

1. Introducción 1
- 1.1. Planteamiento del problema . . . 1
- 1.2. Justificación . . . 1
- 1.3. Objetivos . . . 2
- 1.4. Principales contribuciones . . . 2
- 1.5. Organización del documento . . . 3

2. Marco Teórico 5
- 2.1. Imagen Digital . . . 5
  - 2.1.1. Imagen Digital Monocromática . . . 5
  - 2.1.2. Imagen Digital RGB . . . 5
- 2.2. Imagen Hiperespectral . . . 6
  - 2.2.1. Hipercubo . . . 6
  - 2.2.2. Captura de información dual . . . 6
  - 2.2.3. Resolución y sensibilidad espectral . . . 7
- 2.3. El fenómeno de Hughes . . . 7
- 2.4. Algoritmos Genéticos . . . 8
- 2.5. Optimización por Enjambre de Particulas . . . 8
- 2.6. La Máquina de Soporte Vectorial . . . 8

3. Estado del Arte 9

4. Metodología 11
- 4.1. Adquisición de Datos e Inoculación . . . 13
  - 4.1.1. Material Biológico y Procedencia . . . 13
  - 4.1.2. Diseño Experimental y Proceso de Inoculación . . . 13
  - 4.1.3. Condiciones de Incubación y Monitoreo Temporal . . . 13
- 4.2. Preprocesamiento de Imágenes . . . 14
- 4.3. Extracción de Características y Construcción del Vector . . . 15
- 4.4. Proceso de Optimización . . . 16

4.4.1. Algoritmo Genético 17
4.4.2. Optimización por Enjambre de Partículas 18
4.4.3. Estrategia de Evaluación 18

5. Experimentación y Resultados **19**
5.1. Medidas y Métricas Utilizadas 19
5.2. Configuraciones Experimentales 19
5.3. Caracterización Espectral de las Muestras 20
5.4. Resultados 21
5.4.1. Resultados de la Construcción de Características 21
5.4.2. Análisis Comparativo del Rendimiento: GA y PSO 23

6. Conclusiones **27**
6.1. Aportación al estado del arte 27
6.2. Aportación al área de investigación 27
6.3. Trabajo futuro 27

A. Anexo 1 **29**

Bibliografía **30**

Índice de figuras

2.1. Esquema del cubo de color RGB. Los puntos sobre la diagonal principal tienen valores de la escala de grises, desde el negro en el origen hasta blanco en el punto (1, 1, 1). 6
2.2. Representación gráfica de un cubo hiperespectral. 7

4.1. Diagrama de flujo de la metodología computacional propuesta 12
4.2. Charola de higos antes de la segmentación (a) y mascaras de higos después de la segmentación (b) 15
4.3. Matríz de correlación de medias de reflectancia. 17

5.1. Caracterización espectral de las muestras de higo. (**a**) Firmas de reflectancia media mostrando la tendencia central. (**b**) Desviación estándar de la reflectancia representando la variabilidad espacial (textura). . . 21
5.2. Media de convergencia de las ejecuciones del algoritmo genetico durante 30 ejecuciones independientes para los escenarios: (**a**) 3 Bandas; (**b**) 5 Bandas; y (**c**) 6 Bandas. 23
5.3. Diagrama de cajas: comparación de GA vs. PSO con características ($\mu + \sigma$). 24
5.4. Diagrama de cajas: comparación de GA vs. PSO únicamente con media (μ). 24

Índice de tablas

5.1. Parametros del Algoritmo Genético. 19
5.2. Parametros de PSO. 19
5.3. Parametros de SVM. 20
5.4. Comparación de desempeño GA (F1-Score promedio) entre características. 22

Capítulo 1

Introducción

1.1. Planteamiento del problema

La seguridad alimentaria y la sostenibilidad económica en la agricultura se enfrentan a una amenaza constante debido a la contaminación por hongos patógenos [1]. El hongo *Aspergillus flavus* destaca por su alta peligrosidad, ya que es el principal productor de aflatoxinas, metabolitos secundarios clasificados como carcinógenos humanos del Grupo 1 [1]. La detección de este patógeno es un problema crítico, especialmente en cultivos de alto valor económico como el higo (*Ficus carica*), donde regiones como Extremadura, en España, lideran la producción [1]. Tradicionalmente, la identificación de estas micotoxinas depende de métodos químicos analíticos (como HPLC o ELISA) que resultan destructivos, costosos y sumamente lentos, lo cual impide la inspección del 100 % de la producción agrícola [2, 3]. Aunque las Imágenes Hiperespectrales (HSI) ofrecen una solución no invasiva, la inmensa cantidad de datos generados por las cientos de bandas contiguas presenta un desafío computacional significativo, conocido como la maldición de la dimensionalidad [4, 2, 5]. El problema fundamental radica en cómo procesar eficientemente esta alta dimensionalidad para lograr una detección certera en sistemas de inspección.

1.2. Justificación

Resolver este cuello de botella computacional es imperativo para trasladar la tecnología de laboratorio a la industria y permitir inspecciones no destructivas de toda la producción. La reducción de la dimensionalidad mediante la selección inteligente de bandas espectrales es un paso crucial, ya que el uso de espectros completos requiere hardware sumamente costoso y un alto poder de cómputo [6]. Al mitigar estos requerimientos, los beneficios directos impactan la salud pública al evitar el consumo de aflatoxinas y protegen económicamente a la industria agrícola al prevenir el rechazo de lotes completos de exportación [1].

1.3. Objetivos

Objetivo general

- Evaluar un enfoque híbrido de selección de bandas hiperespectrales mediante algoritmos metaheurísticos y máquinas de vectores de soporte para optimizar la detección no invasiva de *Aspergillus flavus* en higos frescos [1].

Objetivos específicos

- Extraer características espectrales, específicamente la reflectancia media y la desviación estándar, a partir de regiones de interés segmentadas en imágenes hiperespectrales de higos [1].
- Implementar Algoritmos Genéticos y Optimización por Enjambre de Partículas para identificar subconjuntos óptimos de tres, cinco y seis bandas espectrales [7].
- Comparar el rendimiento de los subconjuntos seleccionados evaluando la función de aptitud mediante la métrica F1-Score en un algoritmo de Máquina de Soporte Vectorial [8].

Alcances y Limitaciones

- **Alcances:** El estudio aborda la clasificación binaria entre muestras de control sanas y muestras inoculadas con una concentración severa del hongo de 10^7 CFU/mL [1]. La captura de datos abarca el rango espectral visible e infrarrojo cercano (VNIR) de 400 nm a 1000 nm [9]. La optimización se limita al uso de GA y PSO, y la clasificación se realizará exclusivamente con SVM utilizando un kernel de Función de Base Radial (RBF) [10, 8].
- **Limitaciones:** El desarrollo experimental está acotado al análisis de una única variedad de higo (Calabacita) cultivada en una región específica, y la contaminación se simuló en condiciones controladas de laboratorio utilizando una única cepa del hongo (HG 144M) [1].

1.4. Principales contribuciones

- Implementación de una estrategia de construcción de características que concatena la reflectancia media y la desviación estándar espacial, logrando capturar simultáneamente la tendencia espectral y la heterogeneidad textural de la piel del higo infectado [11, 8].
- Reducción drástica de la complejidad computacional de los datos hiperespectrales, validando que un conjunto reducido de bandas (e.g., cinco bandas) puede alcanzar un rendimiento superior al 83 % en la métrica F1-Score [1].

- Identificación y correlación física de las bandas seleccionadas con regiones biológicamente relevantes del espectro electromagnético, vinculadas a cambios de pigmentación, estructura celular y contenido de agua inducidos por el patógeno [12, 13].

1.5. Organización del documento

El Capítulo 2 establece el marco teórico fundamental sobre imágenes hiperespectrales y algoritmos de optimización. El Capítulo 3 analiza el estado del arte y las metodologías contemporáneas. El Capítulo 4 detalla rigurosamente la metodología propuesta, desde la adquisición de datos hasta la estrategia computacional. El Capítulo 5 expone las métricas, la configuración de la experimentación y el análisis exhaustivo de los resultados. Finalmente, el Capítulo 6 presenta las conclusiones y delinea el trabajo futuro.

Capítulo 2

Marco Teórico

2.1. Imagen Digital

Una imagen digital se define formalmente como una función bidimensional de intensidad, $f(x, y)$, en la cual x e y representan las coordenadas espaciales, mientras que el valor de la amplitud f en cada punto corresponde al nivel de gris o brillo. Cuando las coordenadas espaciales (x, y) y los valores de intensidad son finitos y discretos, la función se clasifica adecuadamente como una imagen digital[14].

2.1.1. Imagen Digital Monocromática

La luz monocromática (o acromática) se refiere a la radiación lumínica completamente desprovista de color. Su único atributo cuantitativo es la intensidad, cuyos valores abarcan desde el negro hasta el blanco a lo largo de la escala de grises; consecuentemente, a las imágenes monocromáticas se las denomina de manera habitual imágenes en escala de grises[14].

2.1.2. Imagen Digital RGB

El modelo de color RGB se fundamenta en un sistema de coordenadas cartesianas donde los colores se representan a través de sus componentes espectrales primarias: rojo, verde y azul. En consecuencia, una imagen estructurada bajo este modelo consta de tres canales de imagen independientes, correspondientes a cada una de dichas componentes primarias[14].

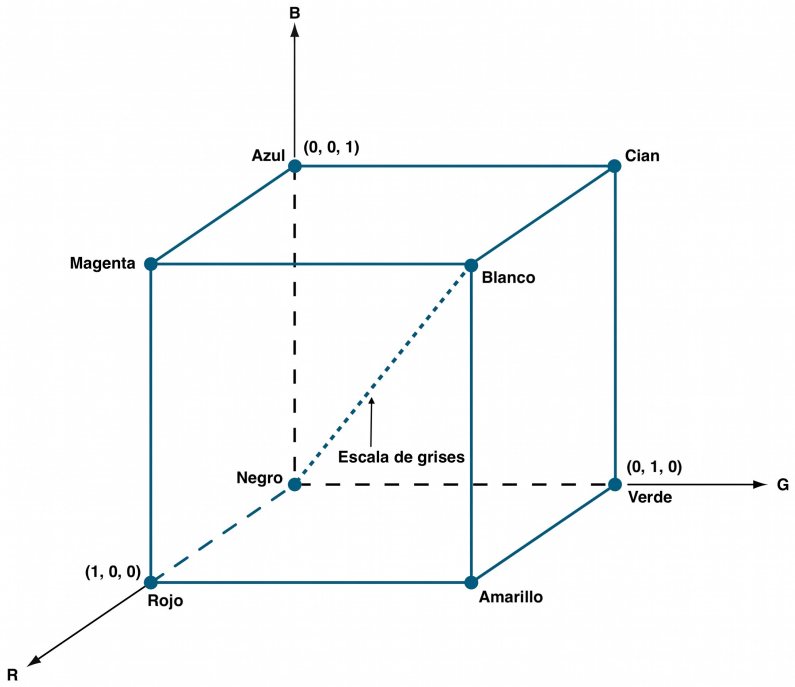


Figura 2.1: Esquema del cubo de color RGB. Los puntos sobre la diagonal principal tienen valores de la escala de grises, desde el negro en el origen hasta blanco en el punto (1, 1, 1).

2.2. Imagen Hiperespectral

Las imágenes hiperespectrales constituyen una técnica avanzada que integra la fotografía digital convencional con la espectroscopia, lo que permite la adquisición simultánea de información espectral y espacial de un objeto[3, 4, 2]. Entre sus características fundamentales destacan las siguientes:

2.2.1. Hipercubo

Las imágenes hiperespectrales capturan datos a lo largo de cientos de bandas espectrales contiguas y estrechas (que abarcan el espectro visible, el infrarrojo cercano y el infrarrojo térmico) para cada píxel de la imagen[3]. Esto genera una estructura tridimensional de datos denominada hipercubo o cubo de datos, la cual comprende dos dimensiones espaciales y una dimensión espectral, la imagen 2.2 es una representación de la estructura de datos del cubo hiperespectral.

2.2.2. Captura de información dual

Dado que se registra el espectro completo para cada píxel y se genera una imagen por cada longitud de onda, la imaginería hiperespectral adquiere simultáneamente

las propiedades físico-geométricas del objeto (tales como morfología, dimensión, color y textura) así como sus propiedades químico-moleculares (incluyendo contenido de agua, lípidos, proteínas y otros compuestos con enlaces de hidrógeno) [3].

2.2.3. Resolución y sensibilidad espectral

Esta técnica destaca por su elevada resolución espacial y espectral, lo que facilita la detección de variaciones sutiles en la composición química y la textura de los materiales. Dichas capacidades se logran mediante la medición de la firma espectral característica de cada objeto, evaluando de forma precisa los patrones de absorción, reflectancia o emisión de radiación electromagnética a lo largo de diversas longitudes de onda [3].

Debido a su habilidad para realizar inspecciones altamente detalladas y no invasivas, las imágenes hiperespectrales son utilizadas ampliamente para inspecciones de calidad y seguridad en agricultura y procesamiento de alimentos.

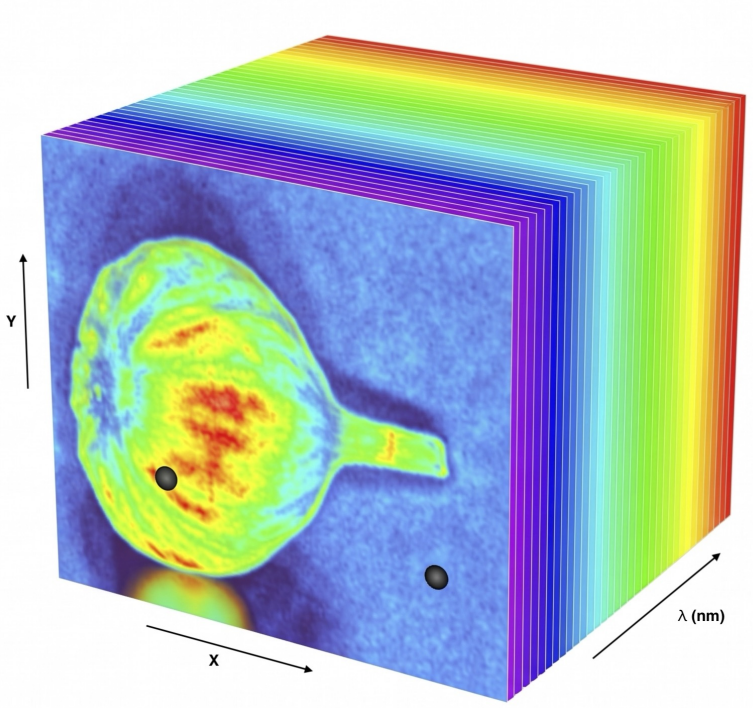


Figura 2.2: Representación gráfica de un cubo hiperespectral.

2.3. El fenómeno de Hughes

El fenómeno de Hughes, también denominado «maldición de la dimensionalidad», constituye un problema estadístico recurrente en el que el incremento en el número de variables o características dentro de un conjunto de datos no repercute necesariamente en una mayor precisión de clasificación. En presencia de un tamaño de muestra

de entrenamiento constante, la incorporación progresiva de dimensiones espectrales puede conducir a la degradación del rendimiento predictivo del modelo. Esta problemática resulta de particular relevancia en el ámbito del procesamiento de imágenes hiperespectrales, dado que los sensores adquieren datos a lo largo de cientos de bandas espectrales contiguas[5, 6]. Si bien dicha resolución facilita la discriminación precisa entre clases y superficies complejas, de forma simultánea introduce diversos desafíos metodológicos y computacionales:

- Redundancia y ruido en los datos: La elevada dimensionalidad inherente a la información hiperespectral suele derivar en una alta correlación entre bandas, así como en la presencia de variables irrelevantes y ruidosas.
- Disminución de la capacidad discriminante: Cuando el número de características supera significativamente al de las muestras de entrenamiento, los modelos experimentan dificultades de generalización, reduciendo paradójicamente la precisión del análisis.
- Elevada carga computacional: La magnitud del volumen de datos incrementa sustancialmente la complejidad algorítmica, afectando negativamente la eficiencia del procesamiento y la velocidad de cálculo.

2.4. Algoritmos Genéticos

Son técnicas de optimización bioinspiradas en la evolución natural [7]. Codifican soluciones candidatas como vectores y aplican operadores evolutivos de selección, cruce y mutación a lo largo de sucesivas generaciones para evitar convergencias prematuras y favorecer la exploración global [15, 7].

2.5. Optimización por Enjambre de Particulas

Es una metaheurística estocástica inspirada en el comportamiento colectivo de las bandadas de aves [7]. Modela a la población como partículas en un espacio n-dimensional, donde la trayectoria de cada partícula es gobernada por una velocidad actualizada mediante una suma ponderada de componentes de inercia, cognitivos y sociales [7, 16].

2.6. La Máquina de Soporte Vectorial

Relleno

Capítulo 3

Estado del Arte

El uso de la tecnología HSI para la detección de enfermedades fúngicas ha sido ampliamente explorado durante la última década, demostrando gran eficacia en la identificación de hongos y aflatoxinas en maíz, cacahuetes y otros frutos secos [3, 1]. En el contexto específico de los higos, investigaciones recientes han aplicado técnicas de aprendizaje profundo, tales como las Redes Neuronales Convolucionales (CNN) y Redes Neuronales Totalmente Conectadas (FCNN) [1]. Estos estudios han establecido precedentes importantes, reportando altas tasas de precisión en la clasificación de píxeles infectados por *Aspergillus flavus* [1].

Sin embargo, el análisis reflexivo de estos enfoques revela una importante limitación tecnológica y operativa: la mayoría de estas arquitecturas neuronales profundas utilizan el espectro electromagnético completo [6]. Esta dependencia exige un hardware sumamente costoso e impone demandas de alto poder computacional, dificultando su escalabilidad y aplicación práctica en entornos agrícolas reales [6].

Para contrarrestar la sobrecarga de datos, la literatura sugiere que la selección de bandas espectrales es un paso ineludible [6]. Tradicionalmente se han empleado métodos estadísticos como el Análisis de Componentes Principales (PCA) para reducir los datos [2]. No obstante, la tendencia actual indica que las técnicas basadas en algoritmos evolutivos están ganando terreno rápidamente debido a su capacidad superior para encontrar soluciones óptimas globales dentro de espacios de búsqueda altamente complejos [6]. Este trabajo cubre directamente este vacío, proponiendo el uso de metaheurísticas no solo para procesar la tendencia central del espectro, sino para incorporar el análisis textural (variabilidad), optimizando la detección sin la costosa dependencia de la redundancia espectral total.

Capítulo 4

Metodología

La metodología desarrollada en este trabajo de investigación se estructuró sistemáticamente en tres fases secuenciales para garantizar su rigor y reproducibilidad técnica como se ilustra en la Figura 4.1.

En primer lugar, se llevó a cabo la adquisición de datos, la cual consistió en la inoculación controlada de los frutos y la captura temporal de sus firmas hiperespectrales. La segunda fase se centró en el preprocesamiento computacional de las imágenes, abarcando la corrección radiométrica, la segmentación espacial de las regiones de interés (ROI) y la posterior extracción de métricas estadísticas representativas (reflectancia media y desviación estándar) para cada muestra. Finalmente, la tercera fase consistió en el diseño e implementación de una estrategia de optimización basada en algoritmos metaheurísticos, cuya aptitud fue evaluada mediante un modelo de Máquina de Soporte Vectorial (SVM). El objetivo de esta última etapa fue reducir drásticamente la dimensionalidad del espacio de datos e identificar el subconjunto óptimo de bandas espectrales para la detección de *Aspergillus flavus*.

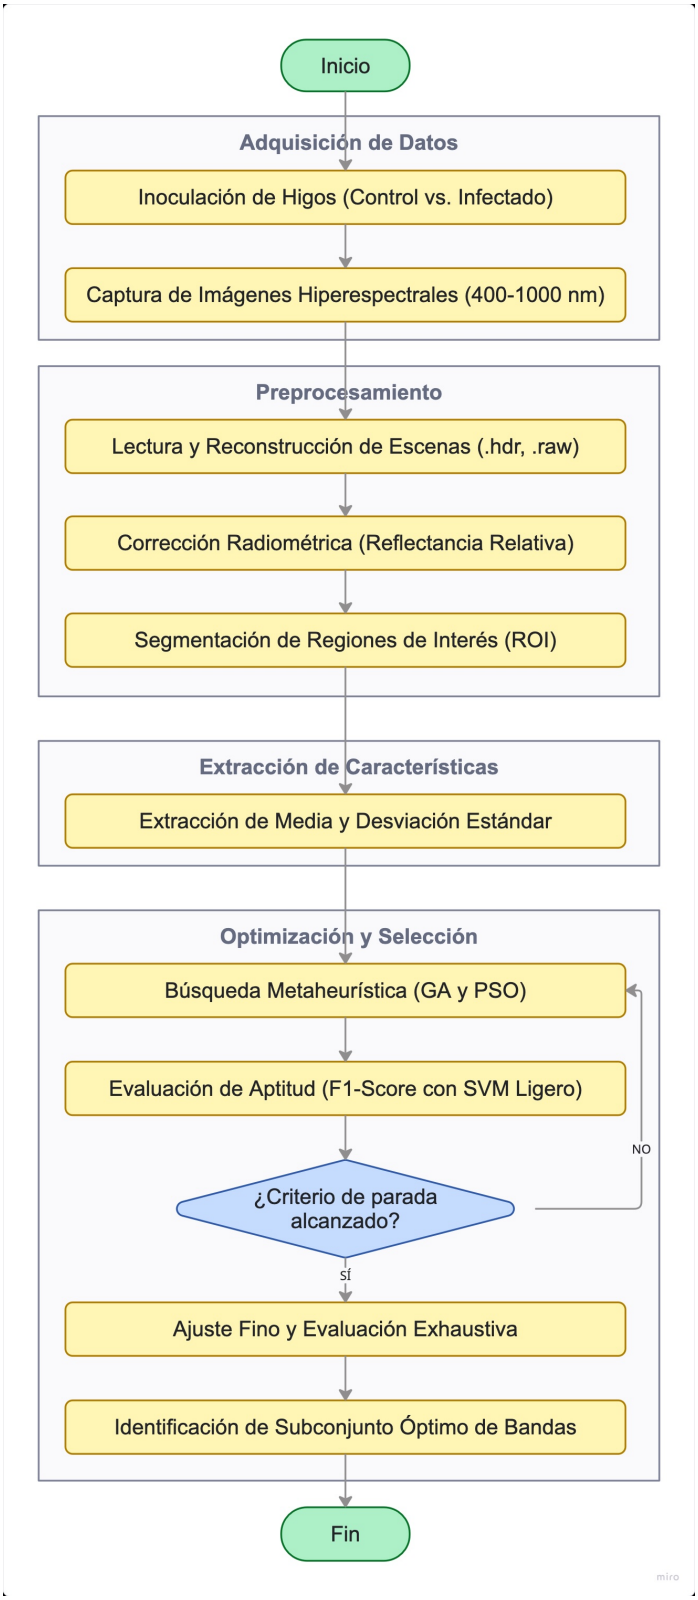


Figura 4.1: Diagrama de flujo de la metodología computacional propuesta

4.1. Adquisición de Datos e Inoculación

4.1.1. Material Biológico y Procedencia

Para el desarrollo de esta investigación, se utilizaron muestras de higos frescos (Ficus carica L.) correspondientes a la variedad Calabacita. Con el fin de garantizar la uniformidad fisiológica del lote de estudio, todas las muestras fueron recolectadas simultáneamente en la "Finca La Orden-Valdesequera", una instalación agrotecnológica operada por el Centro de Investigaciones Científicas y Tecnológicas de Extremadura (CICYTEX), ubicada en la región de Guadajira, Badajoz, España.

4.1.2. Diseño Experimental y Proceso de Inoculación

El protocolo de inoculación fue ejecutado bajo condiciones controladas de laboratorio por ingenieros agrícolas del CICYTEX. Para el diseño del experimento, la población total de frutos se distribuyó en cuatro bandejas independientes, albergando cada una entre 36 y 40 higos. Una de estas bandejas se mantuvo libre de patógenos para fungir como el grupo de control sano (Clase 0).

Las muestras de las tres bandejas restantes fueron sometidas a un proceso de inoculación artificial, el cual consistió en sumergir la porción inferior de cada fruto durante un lapso de 4 a 5 segundos en una solución fúngica. Se utilizó específicamente la cepa Aspergillus flavus HG 144M, provista por la colección del grupo de investigación CAMIALI de la Universidad de Extremadura. Para evaluar la progresión de la enfermedad, las soluciones se prepararon en tres concentraciones distintas: $10^3 UFC/ml$, $10^5 UFC/ml$ y $10^7 UFC/ml$. Sin embargo, para los alcances del presente trabajo computacional, centrado en la clasificación binaria, el conjunto de datos de trabajo se construyó utilizando únicamente el grupo de control sano (Clase 0) y el grupo inoculado con la infección más severa de $10^7 UFC/ml$ (Clase 1).

4.1.3. Condiciones de Incubación y Monitoreo Temporal

Entre las sesiones de adquisición de imágenes, las muestras reposaron en una cámara de incubación bajo un ambiente estrictamente controlado. La cámara se configuró para mantener una temperatura constante de 25°C y una humedad relativa de entre 80 % y 90 %, proporcionando las condiciones ambientales óptimas para la proliferación fúngica.

El monitoreo de las muestras se realizó mediante la captura de imágenes hiperespectrales cada 24 horas durante un periodo de cinco días consecutivos posteriores a la inoculación. La adquisición se efectuó empleando una cámara hiperespectral line-scan (pushbroom) modelo SPECIM FX10. El sensor de este dispositivo captura la reflectancia en el rango espectral visible e infrarrojo cercano (VNIR, 400 nm a 1000 nm), ofreciendo una resolución espectral de 448 bandas y una resolución espacial de 1024 píxeles de ancho por cada línea de escaneo [1].

4.2. Preprocesamiento de Imágenes

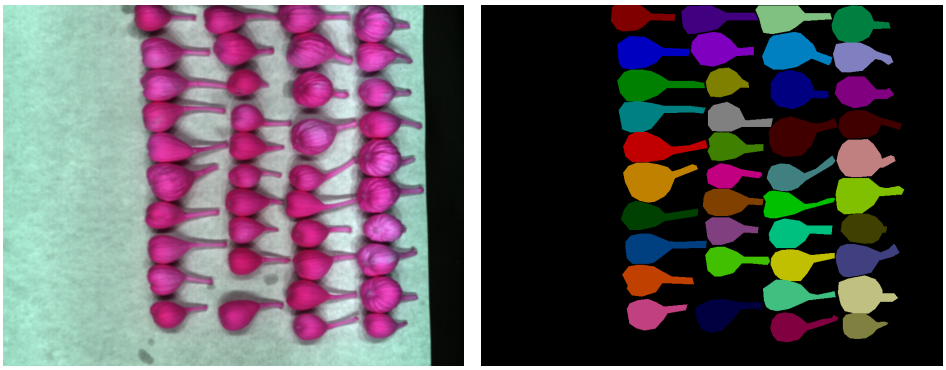
El procesamiento de los datos espaciales y espectrales, así como la extracción inicial de características, se llevó a cabo apoyándose en la biblioteca Spectral Python (SPy) para la manipulación y análisis algorítmico de los cubos hiperespectrales. Como primer paso en el flujo de trabajo, se procedió a la lectura e interpretación de los archivos de encabezado (.hdr) y los archivos de datos binarios (.raw) generados por el sensor SPECIM FX10, lo que permitió reconstruir digitalmente las escenas adquiridas. Como primer paso en el flujo de trabajo, se procedió a la lectura e interpretación de los archivos de encabezado (.hdr) y los archivos de datos binarios (.raw) generados por el sensor SPECIM FX10, lo que permitió reconstruir digitalmente las escenas adquiridas.

Dado que los valores capturados inicialmente por la cámara representan intensidades lumínicas brutas, las cuales están inherentemente sujetas a fluctuaciones de la fuente de iluminación y al ruido térmico del sensor, fue indispensable aplicar una corrección radiométrica. Los valores de intensidad bruta se convirtieron a reflectancia relativa aplicando referencias claras y oscuras adquiridas junto con cada escena, de acuerdo con la siguiente ecuación[17]:

$$R = \frac{I_{raw} - I_{dark}}{I_{white} - I_{dark}} \tag{4.1}$$

Donde I_{raw} corresponde a la intensidad de la imagen bruta, I_{dark} representa la referencia oscura (capturada con el obturador cerrado para medir la corriente oscura del sensor), e I_{white} es la referencia blanca (obtenida mediante un panel de calibración de reflectancia máxima).

Posterior a la calibración, y con el fin de procesar la información espectral de cada fruto de manera individualizada y libre del ruido de fondo, se procesaron un total de 18 escenas hiperespectrales completas. El aislamiento espacial de las Regiones de Interés (ROI) se efectuó a través de una segmentación manual utilizando el software de anotación de código abierto LabelMe (v5.8.3)[18]. Este meticuloso proceso dio como resultado la generación de 560 máscaras de segmentación individuales. Consecuentemente, el conjunto de datos de trabajo final quedó constituido por estas 560 muestras independientes, distribuidas en 277 muestras pertenecientes a la clase de control sana (Clase 0) y 283 muestras correspondientes a la clase inoculada con la concentración severa (Clase 1).



(a) (b)

Figura 4.2: Charola de higos antes de la segmentación (a) y mascaras de higos después de la segmentación (b)

4.3. Extracción de Características y Construcción del Vector

La información contenida en las imágenes hiperespectrales es masiva y altamente redundante entre bandas contiguas. Para modelar el problema de clasificación, fue necesario transformar los datos puros de los píxeles dentro de cada Región de Interés (ROI) en descriptores matemáticos [6].

Con el objetivo de capturar tanto el impacto fisiológico interno (cambios en la pigmentación y contenido de agua) como las alteraciones en la textura superficial del fruto, se diseñó una estrategia de construcción de características basada en dos momentos estadísticos:

1. Reflectancia Media (μ): Caracteriza la tendencia central de la firma espectral, indicando la cantidad de luz promedio que el tejido absorbe o refleja en una longitud de onda específica [8].

2. Desviación Estándar (σ): Cuantifica la variabilidad espacial o heterogeneidad en la superficie del fruto. Esta métrica es de suma importancia biológica, ya que la infección por Aspergillus flavus no es uniforme; la formación de micelio y la esporulación alteran la rugosidad superficial del higo, generando patrones de dispersión de luz irregulares que son capturados por esta medida de dispersión [11].

Formalmente, para una imagen hiperespectral con n bandas (donde $n = 448$), el conjunto completo de características extraídas para la i-ésima muestra se definió mediante el siguiente vector concatenado:

$$X_i = [\mu_i, 1, \ldots \mu_i, n, \sigma_i, 1, \ldots, \sigma_i, n] \tag{4.2}$$

Este enfoque generó un vector inicial de 896 dimensiones por muestra (448 medias y 448 desviaciones estándar). Para mitigar la maldición de la dimensionalidad, el espacio de búsqueda de optimización se estructuró como un problema de selección de bandas. Bajo este esquema, la selección de una banda específica j implica la inclusión simultánea e indisoluble de su media (μ_j) y su desviación estándar (σ_j). Por lo tanto, el algoritmo metaheurístico opera sobre un espacio de búsqueda binario de n dimensiones (donde 1 indica selección y 0 exclusión), pero la dimensionalidad real del vector de características que evalúa el clasificador es de $2 \times k$, siendo k el número objetivo de bandas seleccionadas ($k \in \{3, 5, 6\}$).

El problema de optimización se definió formalmente como la búsqueda del vector binario $B = \{b1, ..., bn\}$ que maximice la función de aptitud, se estableció el F1-Score como la función objetivo a maximizar:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \tag{4.3}$$

Se eligio el F1-Score como la función de aptitud debido a su habilidad para balancear presición y sensibilidad. Es critico penalizar falsos negativos (higos infectados clasificados erroneamente como sanos), ya que representan un alto riesgo para la salud. Ademas, el F1-Score provee una métrica robusta ya que mitiga efectivamente el sesgo potencial introducido por la pequeña diferencia entre la cantidad de higos en Clase 0 y la Clase 1 en el conjunto de datos.

4.4. Proceso de Optimización

Aunque las imágenes hiperespectrales proporcionan una cantidad abundante de información, sufren de alta redundancía debido a la alta correlación entre bandas espectrales contiguas [6]. Esta característica conlleva a la llamada *maldición de la dimensionalidad* o fenomeno de Hughes, donde la presición de la clasificación tiende a decrecer conforme el número de bandas espectrales se incrementa dado un número limitado de muestras de entrenamiento [5]. La figura 4.3 es una matríz de correlación de la reflectancia media de las bandas espectrales del conjunto de datos generado y comprueba que existe una alta redundancía entre las bandas contiguas. Las estructuras prominentes formadas en la diagonal de la matriz son indicadores de grupos de correlación con coeficientes cercanos a 1. Sumado a lo anterior el alto volumen de datos incrementa la carga computacional requerida para su procesamiento.

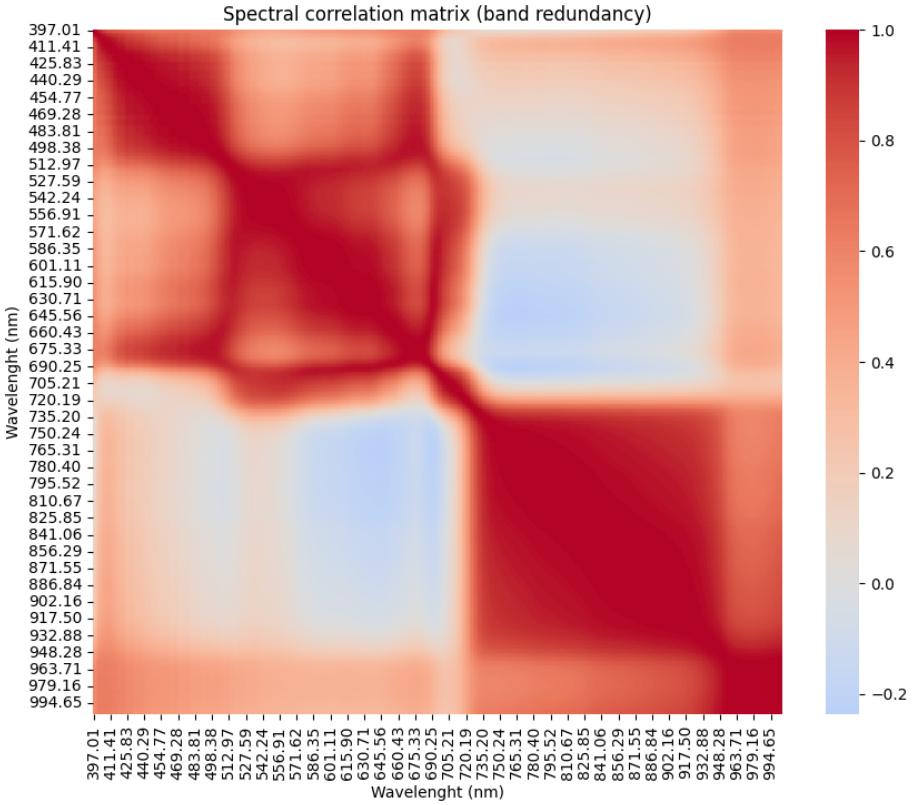


Figura 4.3: Matríz de correlación de medias de reflectancia.

Para abordar estos desafíos, la selección de bandas ha demostrado ser una estrategia eficaz para la reducción de la dimensionalidad, permitiendo eliminar la redundancia y conservar, al mismo tiempo, las características espectrales con mayor poder discriminante [6][8]. Se diseñó un enfoque de optimización basado en metaheurísticas para realizar la de selección de características y mitigar la maldición de la dimensionalidad. La meta principal fue encontrar un vector binario de 448 bits (donde un valor de «1» índica la selección de la banda espectral y «0» su exclusión) que maximizara la capacidad de clasificación del sistema para subconjuntos objetivo de $k \in \{3, 5, 6\}$ bandas. Por el motivo anterior se implementaron y compararon dos algoritmos de optimización metaheurística: algoritmo genético (GA) y Optimización por Enjambre de Partículas (PSO).

4.4.1. Algoritmo Genético

El Algoritmo Genético es una técnica de optimización bioinspirada en la evolución natural y la recombinación genética. En esta implementación, la población de soluciones candidatas (individuos) se codificó mediante la mencionada cadena binaria. A través de sucesivas generaciones, el algoritmo aplicó operadores evolutivos de selección (por torneo), cruce (de un solo punto) y mutación para explorar el espacio

de soluciones [7][15]. La configuración paramétrica específica fue diseñada para evitar convergencias prematuras y favorecer la exploración de combinaciones espectrales complejas.

4.4.2. Optimización por Enjambre de Partículas

Como técnica estocástica alternativa, se implementó el algoritmo PSO, el cual modela la población como un enjambre de partículas que navegan en un espacio n-dimensional. A diferencia de las metodologías estándar, para esta investigación se implementaron Coeficientes de Aceleración Variables en el Tiempo (TVAC).

Esta modificación fue crucial para controlar dinámicamente el comportamiento del enjambre: el coeficiente cognitivo (c_1) decreció linealmente para incentivar la exploración global en las etapas iniciales, mientras que el coeficiente social (c_2) se incrementó linealmente para promover la explotación local (convergencia) en las etapas finales del proceso iterativo. La actualización de las velocidades se rigió por las siguientes ecuaciones:

$$c_1(t) = (c_{1,f} - c_{1,i})\frac{t}{T_{max}} + C_{1,i} \tag{4.4}$$

$$c_2(t) = (c_{2,f} - c_{2,i})\frac{t}{T_{max}} + C_{2,i} \tag{4.5}$$

Donde t es la iteración actual, T_{max} es el número máximo de iteraciones, y los subíndices i y f representan los valores iniciales y finales de cada coeficiente, respectivamente.

4.4.3. Estrategia de Evaluación

Para cuantificar la aptitud de los subconjuntos de bandas propuestos por el GA y el PSO, se utilizó una Máquina de Soporte Vectorial (SVM) con un kernel de Función de Base Radial (RBF). Sin embargo, evaluar iterativamente miles de soluciones candidatas exige un costo computacional excepcionalmente alto. Para mitigar este cuello de botella, se diseñó una estrategia de evaluación en dos etapas:

1. Evaluador Rápido (Función de Aptitud): Se configuró un modelo SVM ligero, con regularización fija $C = 1.0$ y una validación cruzada $K = 3$. Su objetivo fue estimar rápidamente la aptitud (*F1-Score*) de los individuos generados en cada iteración para guiar eficientemente la búsqueda de las metaheurísticas, priorizando la velocidad de ejecución sobre la exactitud absoluta.

2. Evaluador Exhaustivo (Ajuste Fino): Una vez que las metaheurísticas finalizaron su proceso iterativo y entregaron el subconjunto óptimo global de bandas, este se sometió a una optimización rigurosa de hiperparámetros mediante *Grid Search* con: C de 0.1 a 100 y Gamma de 0.001 a 1 y validación cruzada de $K = 5$. Esto garantizó la extracción del máximo rendimiento predictivo del conjunto final.

Capítulo 5

Experimentación y Resultados

5.1. Medidas y Métricas Utilizadas

Para evaluar la aptitud funcional de las bandas seleccionadas, la métrica elegida fue el F1-Score. Esta medida es fundamental porque balancea la precisión y la sensibilidad, penalizando rigurosamente los falsos negativos (clasificar un higo infectado como sano), un escenario que representa un riesgo inaceptable para la seguridad alimentaria [1].

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \tag{5.1}$$

5.2. Configuraciones Experimentales

Ambos algoritmos metaheurísticos fueron ejecutados de manera independiente 30 veces para cada tamaño de subconjunto objetivo ($k \in \{3, 5, 6\}$) [7]. En las siguientes tablas se muestran las configuraciones del GA, PSO y SVM respectivamente:

Tabla 5.1: Parametros del Algoritmo Genético.

Generaciones	**Tamaño de población**	**Tipo de selección**	**Cruza**	**Tasa de mutación**
350	250	Torndeo de 2	Cruza de un punto	2.5

Tabla 5.2: Parametros de PSO.

Iteraciones	**Particulas**	**Coeficiente cognitivo (C1)**	**Coeficiente social (C2)**	**Inercia**	**Tasa de mutación**
650	200	0.4 a 2.5	2.5 a 0.4	0.7	0.2

Tabla 5.3: Parametros de SVM.

Implementación	**Kernel**	**regularización (C)**	**Gamma (γ)**	**Método de validación**
Fast evaluator	RBF	Fixed 1.0	Fixed scale	k-fold CV ($k = 3$)
Exhaustive evaluator	RBF	Grid search 0.1 a 1000	Grid search 0.001 a 1	k-fold CV ($k = 5$)

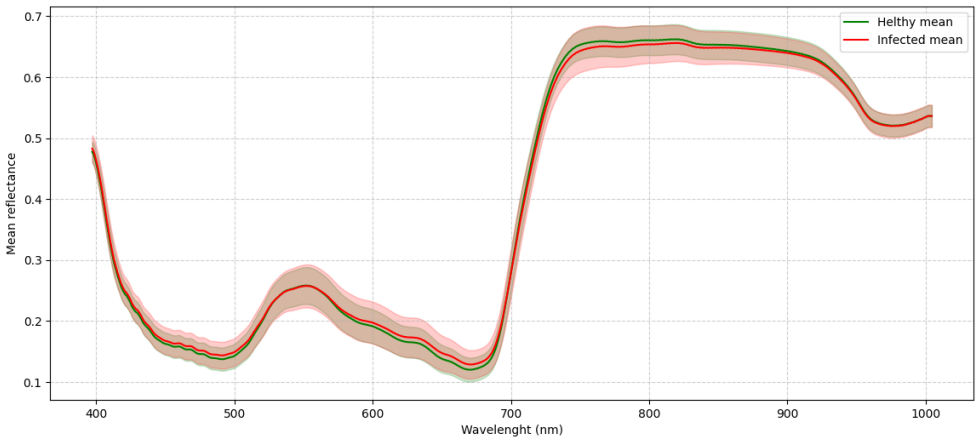
5.3. Caracterización Espectral de las Muestras

Como paso previo a la evaluación del rendimiento de los algoritmos de clasificación y optimización, se realizó un análisis exploratorio del comportamiento espectral de las muestras en el rango VNIR (400 nm a 1000 nm). Este análisis es fundamental para comprender la naturaleza de los datos y justificar la pertinencia de las características extraídas.

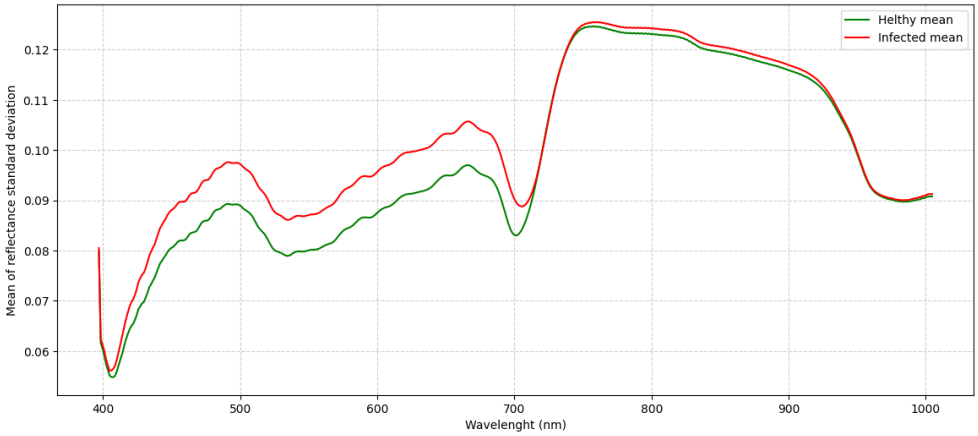
La Figura 5.1 ilustra las firmas espectrales promedio de reflectancia tanto para la clase de frutos sanos (control) como para la clase con infección severa por Aspergillus flavus. Las regiones sombreadas representan la desviación estándar, ilustrando la dispersión de los datos dentro de cada clase. Como se puede observar, los patrones espectrales de ambas clases presentan una similitud visual extremadamente alta, evidenciando un solapamiento casi total en la región del espectro visible (400 - 700 nm). Se aprecia una divergencia sutil en la intensidad de reflectancia únicamente en la región del infrarrojo cercano (NIR, 700 - 1000 nm), un fenómeno atribuible a la degradación de la estructura celular interna del tejido del higo inducida por la colonización fúngica. Este alto grado de solapamiento espectral confirma la complejidad intrínseca de la tarea de clasificación y justifica la necesidad de emplear técnicas avanzadas de selección de bandas en lugar de umbrales espectrales simples.

Sin embargo, el análisis de la variabilidad espacial revela un comportamiento diametralmente distinto. La Figura 5.1b presenta la desviación estándar de la reflectancia en función de la longitud de onda para ambas clases. En esta representación, se evidencia de manera contundente que las muestras infectadas exhiben una variabilidad espacial (textural) consistentemente superior en comparación con los higos sanos a lo largo de todo el espectro.

Esta evidencia empírica respalda la hipótesis central de la metodología propuesta: la infección fúngica, altera la heterogeneidad en la superficie del higo. Por lo tanto, se confirma que la inclusión de la desviación estándar (σ) en el vector de características no es redundante, sino que aporta información discriminatoria crítica que la reflectancia media (μ) por sí sola es incapaz de capturar.



(a)



(b)

Figura 5.1: Caracterización espectral de las muestras de higo. (**a**) Firmas de reflectancia media mostrando la tendencia central. (**b**) Desviación estándar de la reflectancia representando la variabilidad espacial (textura).

5.4. Resultados

Una vez confirmada la relevancia espectral de las características extraídas, se procedió a evaluar el rendimiento cuantitativo de los algoritmos metaheurísticos en la tarea de reducción de dimensionalidad y clasificación.

5.4.1. Resultados de la Construcción de Características

El primer experimento tuvo como objetivo validar computacionalmente la hipótesis planteada en la sección anterior: la superioridad del vector de características combinado ($\mu + \sigma$) sobre el uso exclusivo de la reflectancia media (μ). Para ello, se ejecutó el proceso de selección de bandas bajo ambas configuraciones, estableciendo

do tamaños de subconjuntos objetivo de $k \in \{3, 5, 6\}$ a lo largo de 30 ejecuciones independientes.

Los resultados, promediados y presentados en la Tabla 5.4, demuestran que la inclusión de la desviación estándar mejora significativamente la exactitud del modelo. Incrementando la métrica *F1-Score* particularment en los subconjuntos de menor dimensionalidad, alcanzando una mejora del +9.2 % para $k = 3$ y del +7.2 % para $k = 5$

Tabla 5.4: Comparación de desempeño GA (F1-Score promedio) entre características.

Tamaño de individuo	**Solo media de reflectancia (μ)**	**Características combinadas ($\mu + \sigma$)**	**Mejora (%)**
3 Bandas	0.663	0.755	+9.2 %
5 Bandas	0.698	0.77	+7.2 %
6 Bandas	0.721	0.773	+5.2 %

Adicionalmente, el análisis del historial de convergencia del Algoritmo Genético (Figura 5.2) confirma que la estrategia combinada no solo inicia con una aptitud superior desde las primeras generaciones, sino que mantiene una trayectoria de optimización mucho más robusta. Esto sugiere que la información textural estabiliza el espacio de búsqueda, permitiendo a la metaheurística eludir mínimos locales y converger hacia soluciones de mayor calidad con mayor eficiencia.

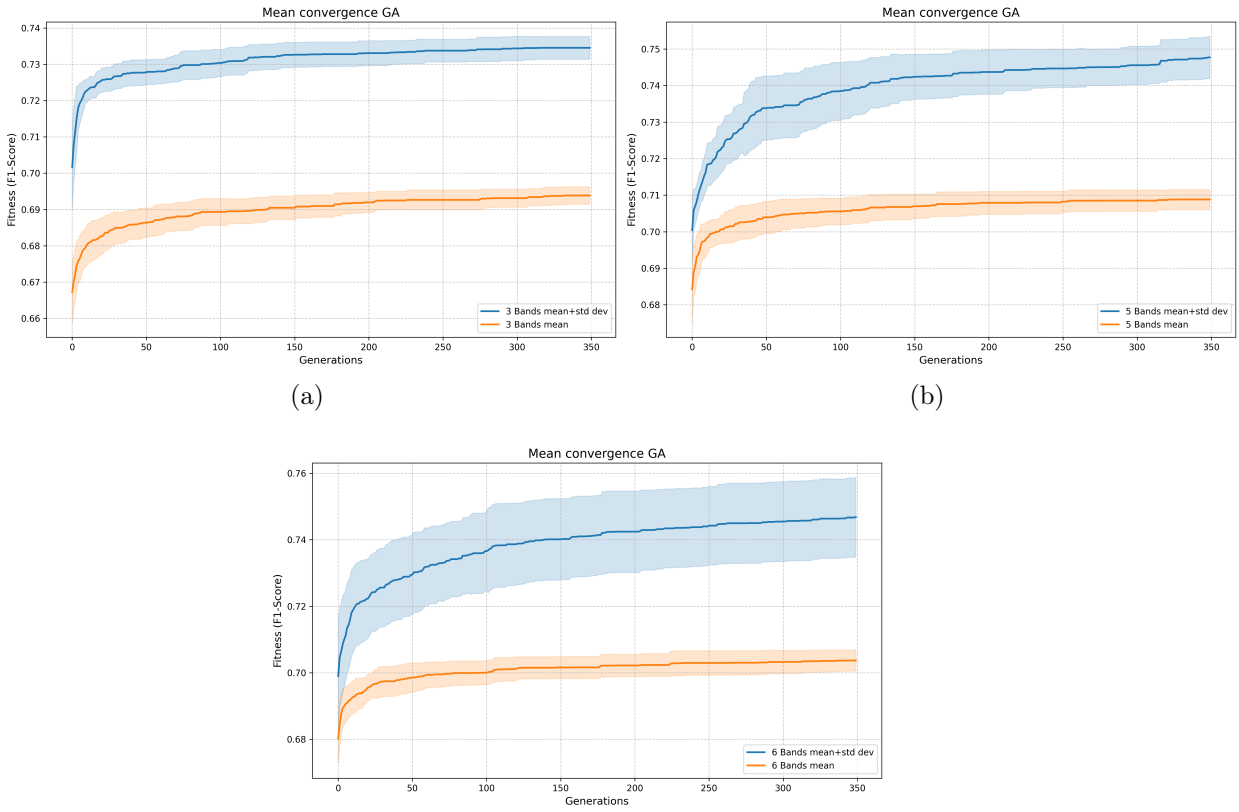


Figura 5.2: Media de convergencia de las ejecuciones del algoritmo genetico durante 30 ejecuciones independientes para los escenarios: (**a**) 3 Bandas; (**b**) 5 Bandas; y (**c**) 6 Bandas.

5.4.2. Análisis Comparativo del Rendimiento: GA y PSO

Tras validar la construcción del vector, el segundo análisis se enfocó en contrastar las capacidades de optimización global del Algoritmo Genético frente a la Optimización por Enjambre de Partículas. La distribución estadística de los valores F1-Score obtenidos tras 30 ejecuciones independientes se resume mediante diagramas de caja en la Figura 5.3.

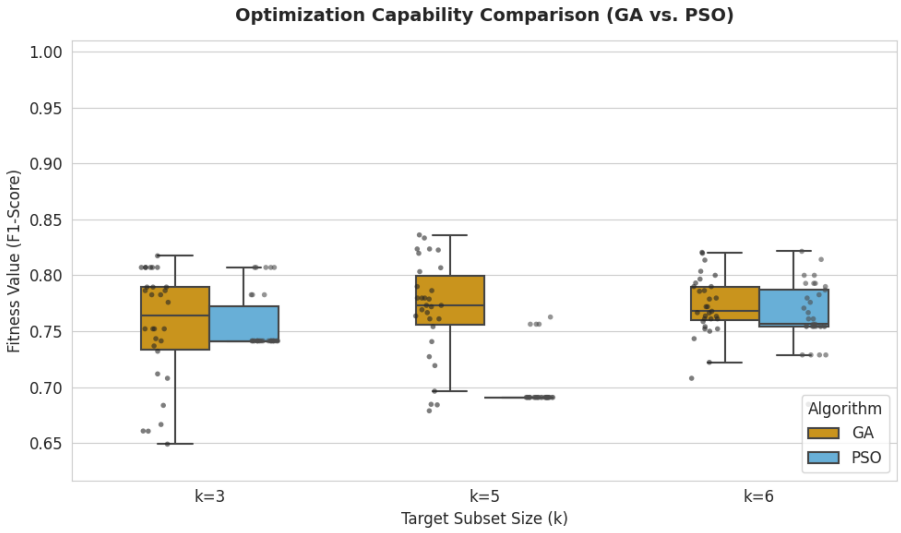


Figura 5.3: Diagrama de cajas: comparación de GA vs. PSO con características (μ+σ).

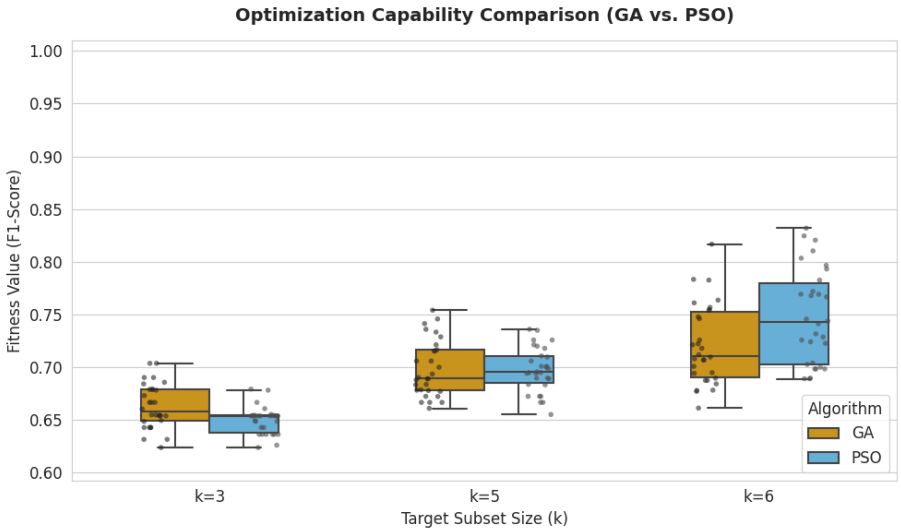


Figura 5.4: Diagrama de cajas: comparación de GA vs. PSO únicamente con media (μ).

El análisis comparativo revela que ambas metaheurísticas son altamente competentes para la selección de bandas hiperespectrales, aunque presentan sutiles diferencias en su comportamiento. El GA demostró una consistencia general ligeramente superior, exhibiendo una mediana de F1-Score más alta y rangos intercuartílicos más estrechos para los subconjuntos de 5 y 6 bandas. Esta menor dispersión indica una mayor estabilidad algorítmica y reproducibilidad en sus resultados.

Por otro lado, el algoritmo PSO mostró una ligera ventaja competitiva en el escenario más restrictivo (3 bandas). Más importante aún, el PSO fue el algoritmo capaz

de encontrar el óptimo absoluto global de todo el estudio: un F1-Score máximo de 0.836 utilizando la configuración de 5 bandas combinadas. Este hallazgo subraya la excelente capacidad de explotación local que otorgan los Coeficientes de Aceleración Variables en el Tiempo (TVAC) implementados en el PSO.

En conclusión, los resultados validan que es posible reducir drásticamente la dimensionalidad de los datos hiperespectrales (pasando de cientos de bandas a un conjunto óptimo de cinco) sin sacrificar la precisión diagnóstica para la detección de Aspergillus flavus, sentando un precedente viable para la implementación de futuros sistemas de inspección agrícola.

Capítulo 6

Conclusiones

6.1. Aportación al estado del arte

Este trabajo demostró con éxito que los algoritmos metaheurísticos poseen capacidades de optimización comparables y sumamente robustas para abordar la selección de bandas espectrales en patología agrícola [6]. La metodología propuesta consiguió comprimir datos hiperespectrales de altísima dimensionalidad hacia un subconjunto compacto de variables, permitiendo mantener la precisión predictiva eliminando simultáneamente el profundo costo computacional que exige el procesamiento del espectro completo [6].

6.2. Aportación al área de investigación

El estudio valida empíricamente que la inclusión de métricas de variabilidad espacial, como la desviación estándar de la reflectancia, es crítica para la clasificación de infecciones fúngicas [8]. Los resultados confirman que al añadir este componente textural, los subconjuntos de dimensionalidad baja incrementan drásticamente su precisión diagnóstica [8]. Además, se comprobó la consistencia física del método computacional al demostrar que las bandas matemáticamente óptimas corresponden directamente a las alteraciones fisiológicas inducidas por la colonización fúngica, tales como la alteración de pigmentos y el estrés hídrico de los tejidos [12, 13].

6.3. Trabajo futuro

Basados en los resultados presentes, el futuro de esta línea de investigación debe dirigirse hacia la Exploración de Optimización Multiobjetivo, buscando algoritmos que encuentren frentes de Pareto para maximizar la precisión mientras minimizan iterativamente la cantidad de bandas sin depender de tamaños objetivo fijos [15]. Asimismo, se planea implementar clasificadores avanzados más robustos ante relaciones no lineales, como Random Forest o XGBoost [8]. Finalmente, el desarrollo

de estrategias co-evolutivas permitirá que las poblaciones de bandas seleccionadas y los hiperparámetros de los modelos clasificadores evolucionen de manera simultánea, descubriendo combinaciones espectrales altamente complejas y eficientes [15].

Apéndice A

Anexo 1

// Puede incluir en un anexo: formularios, entrevistas, encuestas, carta de aceptación a revista. Todos los anexos deben ser referenciados.

Bibliografía

[1] Cristian Cruz-Carrasco, Josefa Díaz-Álvarez, Francisco Chávez De La O, Abel Sánchez-Venegas, and Juan Villegas Cortez. Detection of Aspergillus flavus in Figs by Means of Hyperspectral Images and Deep Learning Algorithms. *AgriEngineering*, 6(4):3969–3988, October 2024.

[2] Xuan Chu, Wei Wang, Xinzhi Ni, Chunyang Li, and Yufeng Li. Classifying maize kernels naturally infected by fungi using near-infrared hyperspectral imaging. *Infrared Physics & Technology*, 105:103242, March 2020.

[3] Bosoon Park and Renfu Lu, editors. *Hyperspectral Imaging Technology in Food and Agriculture*. Food Engineering Series. Springer New York, New York, NY, 2015.

[4] Chunying Wang, Baohua Liu, Lipeng Liu, Yanjun Zhu, Jialin Hou, Ping Liu, and Xiang Li. A review of deep learning used in the hyperspectral image analysis for agriculture. *Artificial Intelligence Review*, 54(7):5205–5253, October 2021.

[5] G. Hughes. On the mean accuracy of statistical pattern recognizers. *IEEE Transactions on Information Theory*, 14(1):55–63, January 1968.

[6] Shrutika Sawant and Manoharan Prabukumar. A survey of band selection techniques for hyperspectral image classification. *Journal of Spectral Imaging*, page a5, June 2020.

[7] A.E. Eiben and J.E. Smith. *Introduction to Evolutionary Computing*. Natural Computing Series. Springer Berlin Heidelberg, Berlin, Heidelberg, 2015.

[8] Koushik Nagasubramanian, Sarah Jones, Soumik Sarkar, Asheesh K. Singh, Arti Singh, and Baskar Ganapathysubramanian. Hyperspectral band selection using genetic algorithm and support vector machines for early identification of charcoal rot disease in soybean stems. *Plant Methods*, 14(1):86, December 2018.

[9] Specim. Specim FX10 - User Manual 2.2, 2020.

[10] Maria Angela Musci, Luigi Mazzara, and Andrea Maria Lingua. Ice Detection on Aircraft Surface Using Machine Learning Approaches Based on Hyperspectral and Multispectral Images. *Drones*, 4(3):45, August 2020.

[11] Eftekhar Hossain, Md. Farhad Hossain, and Mohammad Anisur Rahaman. A Color and Texture Based Approach for the Detection and Classification of Plant Leaf Disease Using KNN Classifier. In *2019 International Conference on Electrical, Computer and Communication Engineering (ECCE)*, pages 1–6, Cox'sBazar, Bangladesh, February 2019. IEEE.

[12] Anne-Katrin Mahlein. Plant Disease Detection by Imaging Sensors – Parallels and Specific Demands for Precision Agriculture and Plant Phenotyping. *Plant Disease*, 100(2):241–251, February 2016.

[13] Bart M. Nicolaï, Katrien Beullens, Els Bobelyn, Ann Peirs, Wouter Saeys, Karen I. Theron, and Jeroen Lammertyn. Nondestructive measurement of fruit and vegetable quality by means of NIR spectroscopy: A review. *Postharvest Biology and Technology*, 46(2):99–118, November 2007.

[14] Rafael C. Gonzalez and Richard E. Woods. *Digital image processing.* Pearson, New York, NY, 2018.

[15] Kalyanmoy Deb. *Multi-Objective Optimization using Evolutionary Algorithms.* Wiley Publishing, 2001.

[16] A. Ratnaweera, S.K. Halgamuge, and H.C. Watson. Self-Organizing Hierarchical Particle Swarm Optimizer With Time-Varying Acceleration Coefficients. *IEEE Transactions on Evolutionary Computation*, 8(3):240–255, June 2004.

[17] Alejandro Morales, Pablo Horstrand, Raúl Guerra, Raquel Leon, Samuel Ortega, María Díaz, José M. Melián, Sebastián López, José F. López, Gustavo M. Callico, Ernestina Martel, and Roberto Sarmiento. Laboratory Hyperspectral Image Acquisition System Setup and Validation. *Sensors*, 22(6):2159, March 2022.

[18] Kentaro Wada, Mpitid, Martijn Buijs, N. Zhang Ch., Narumi, Bc. Martin Kubovčík, Alex Myczko, Latentix, Lingjie Zhu, Naoya Yamaguchi, Shohei Fujii, Iamgd67, IlyaOvodov, Akshar Patel, Christian Clauss, Eisoku Kuroiwa, Roger Iyengar, Sergei Shilin, Tanya Malygina, Kento Kawaharazuka, Jonne Engelberts, Aleksi J, AlexMa, Changwoo Song, Charlie, Daniel Rose, Douglas Livingstone, Doug, Erik, and Henrik Toft. wkentaro/labelme: v4.6.0, November 2021.

[19] Alicia Rodríguez, Mar Rodríguez, M. Isabel Luque, Alberto Martín, and Juan J. Córdoba. Real-time PCR assays for detection and quantification of aflatoxin-producing molds in foods. *Food Microbiology*, 31(1):89–99, August 2012.

[20] Seyed Mohamad Javidan, Ahmad Banakar, Keyvan Asefpour Vakilian, Yiannis Ampatzidis, and Kamran Rahnama. Early detection and spectral signature identification of tomato fungal diseases (Alternaria alternata, Alternaria solani, Botrytis cinerea, and Fusarium oxysporum) by RGB and hyperspectral image analysis and machine learning. *Heliyon*, 10(19), October 2024.

[21] Ana Isabel Galván, Alejandro Hernández, María De Guía Córdoba, Alberto Martín, Manuel Joaquín Serradilla, Margarita López-Corrales, and Alicia Rodríguez. Control of toxigenic Aspergillus spp. in dried figs by volatile organic compounds (VOCs) from antagonistic yeasts. *International Journal of Food Microbiology*, 376:109772, September 2022.

[22] Ana Isabel Galván, María De Guía Córdoba, Alicia Rodríguez, Alberto Martín, Margarita López-Corrales, Santiago Ruiz-Moyano, and Manuel Joaquín Serradilla. Evaluation of fungal hazards associated with dried fig processing. *International Journal of Food Microbiology*, 365:109541, March 2022.

[23] A.J. Galán, A. Martín, L.M. Torres-Vila, S. Ruiz-Moyano, A.I. Galván, M.J. Serradilla, and M. López-Corrales. Quantification and identification of damage caused by pests and fungi in dried figs from orchards with different levels of agronomic management in the main production areas of extremadura (SW Spain). *Crop Protection*, 172:106334, October 2023.

[24] Cavit Bircan. Incidence of ochratoxin A in dried fruits and co-occurrence with aflatoxins in dried figs. *Food and Chemical Toxicology*, 47(8):1996–2001, August 2009.

[25] Shriroop C. Madiwalar and Medha V. Wyawahare. Plant disease identification: A comparative study. In *2017 International Conference on Data Management, Analytics and Innovation (ICDMAI)*, pages 13–18, Pune, India, February 2017. IEEE.

[26] Abdulrahman Bukhari, Bullo Mamo, Mst Shamima Hossain, Ziliang Zhang, Mohsen Karimi, Daniel Enright, Patricia Manosalva, and Hyoseung Kim. Low-Cost Sensing and Classification for Early Stress and Disease Detection in Avocado Plants, 2025. Version Number: 1.

[27] FAO. FAO Statistics, 2025.

[28] Huajian Liu, Brooke Bruning, Trevor Garnett, and Bettina Berger. The Performances of Hyperspectral Sensors for Proximal Sensing of Nitrogen Levels in Wheat. *Sensors*, 20(16):4550, August 2020.